INDONESIAN TECH JOB MARKET ANALYSIS

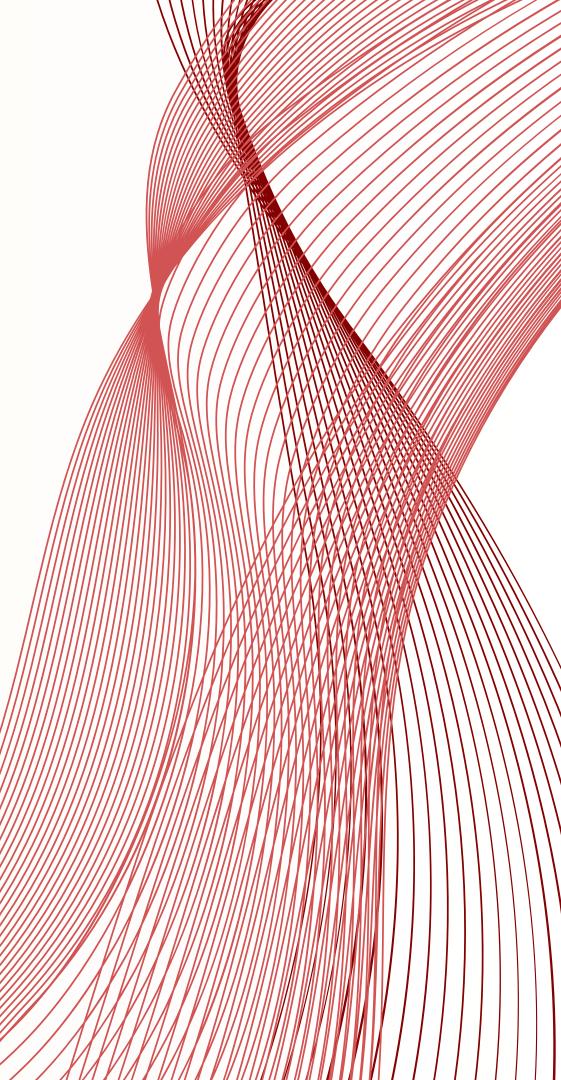
FINAL PROJECT

FITRAN DWI PRAMAKRISNA











FITRAN DWI PRAMAKRISNA

Education

S1 Software Engineering - Institut Teknologi
 Telkom Purwokerto (2018 - 2022)

Work Experience

IT Staff Support - Pelindo Solusi Digital (2022 - present)

Overview Projects

Web Scraping Sneakers Product

Scraping sneakers product using Selenium and Requests library

ETL with Airflow

Creating an ETL pipeline with dynamic DAGs in Airflow

Amazon Sales Report Data Modeling

Creating dimensional and fact table in Google BigQuery using DBT from Amazaon Sales Report Dataset

Big Data Analytics using PySpark

Creating a customer retention analysis using Spark and Airflow for the ETL process with batch processing

Stream Processing using Spark Structured Streaming

Creating a real-time data streaming ingesting data from Apache Kafka that applies aggregation calculation for the output

PROJECT BACKGROUND

WHAT AND WHY THIS PROJECT?

Proyek ini bertujuan untuk membangun sebuah data pipeline ETL (Extract, Transform, dan Load) yang berfungsi dalam mengumpulkan, memproses, dan menyajikan data terkait pasar kerja di bidang teknologi di Indonesia. Dalam proses ini, data akan diekstraksi dari portal lowongan pekerjaan. Hasil akhir dari pipeline ini adalah data yang telah terstruktur dan dimuat ke dalam sistem penyimpanan yang memungkinkan eksplorasi lebih lanjut menggunakan data visualization tool.

Dengan adanya pipeline ini, proyek ini diharapkan dapat memberikan wawasan mendalam mengenai tren perekrutan, keterampilan yang paling dibutuhkan, serta perkembangan pasar kerja di industri teknologi di Indonesia.

PROBLEM STATEMENT

PROBLEMS

Masalah yang tercipta yang mendukung project ini dibuat:

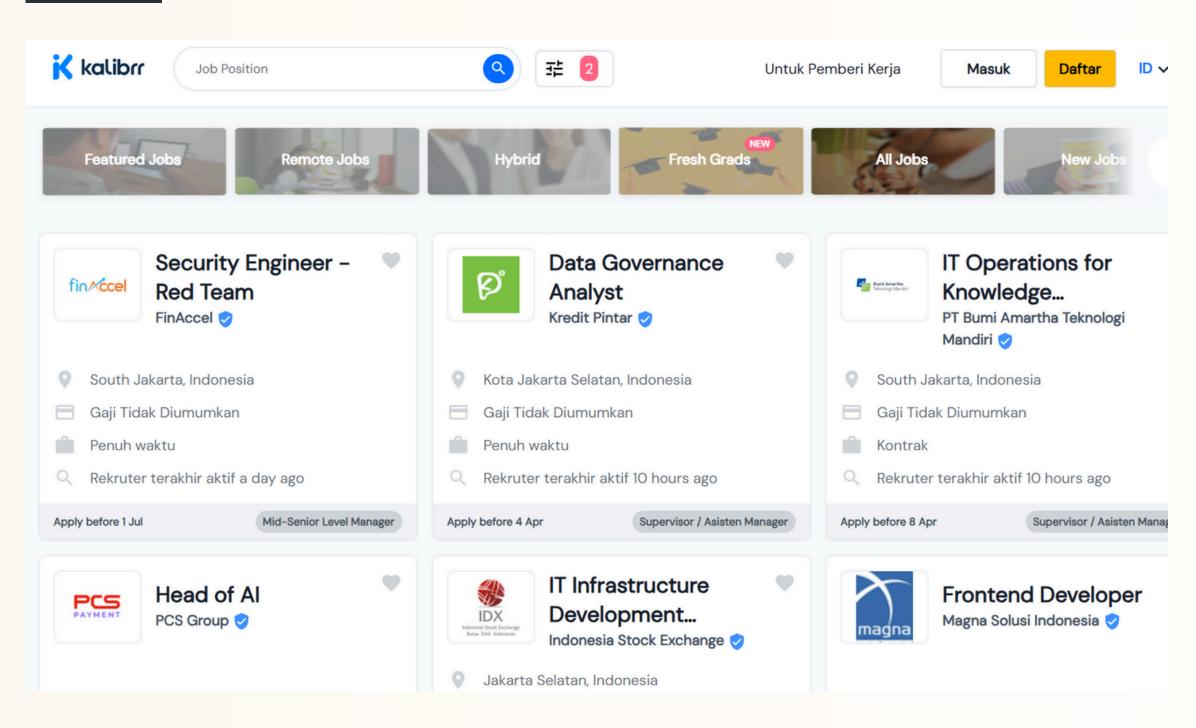
- 1. Sulitnya Memantau Perubahan dan Tren Pasar Kerja, tren pasar kerja di industri teknologi berkembang dengan cepat. Namun, tidak ada sistem otomatis yang dapat mengumpulkan dan memproses data secara berkala, sehingga banyak insight yang seharusnya bisa didapatkan menjadi kurang relevan karena datanya tidak ter-update.
- 2. **Membantu Pengambilan Keputusan Berdasarkan Data bagi Job Seeker**, dapat melihat pekerjaan mana yang sedang *hot*, keterampilan dan jumlah pengalaman kerja yang paling banyak dibutuhkan. Hal ini dapat membuat job seeker bisa menyesuaikan pengalaman dan juga skill mereka
- 3. Tidak Adanya Sumber Data Terpusat untuk Job Market Teknologi, Saat ini, informasi tentang lowongan pekerjaan di industri teknologi tersebar di berbagai platform, seperti situs job portal dan website perusahaan. Namun, tidak ada satu sumber data yang mengintegrasikan informasi ini secara komprehensif untuk memudahkan analisis dan pengambilan keputusan bagi pencari kerja

DATA & PLATFORM UNDERSTANDING

WHAT KIND OF DATA??

Data diperoleh dari metode web scraping menggunakan Request pada python. Website yang akan di-scraping tentunya adalah website-website yang legal untuk di-scraping

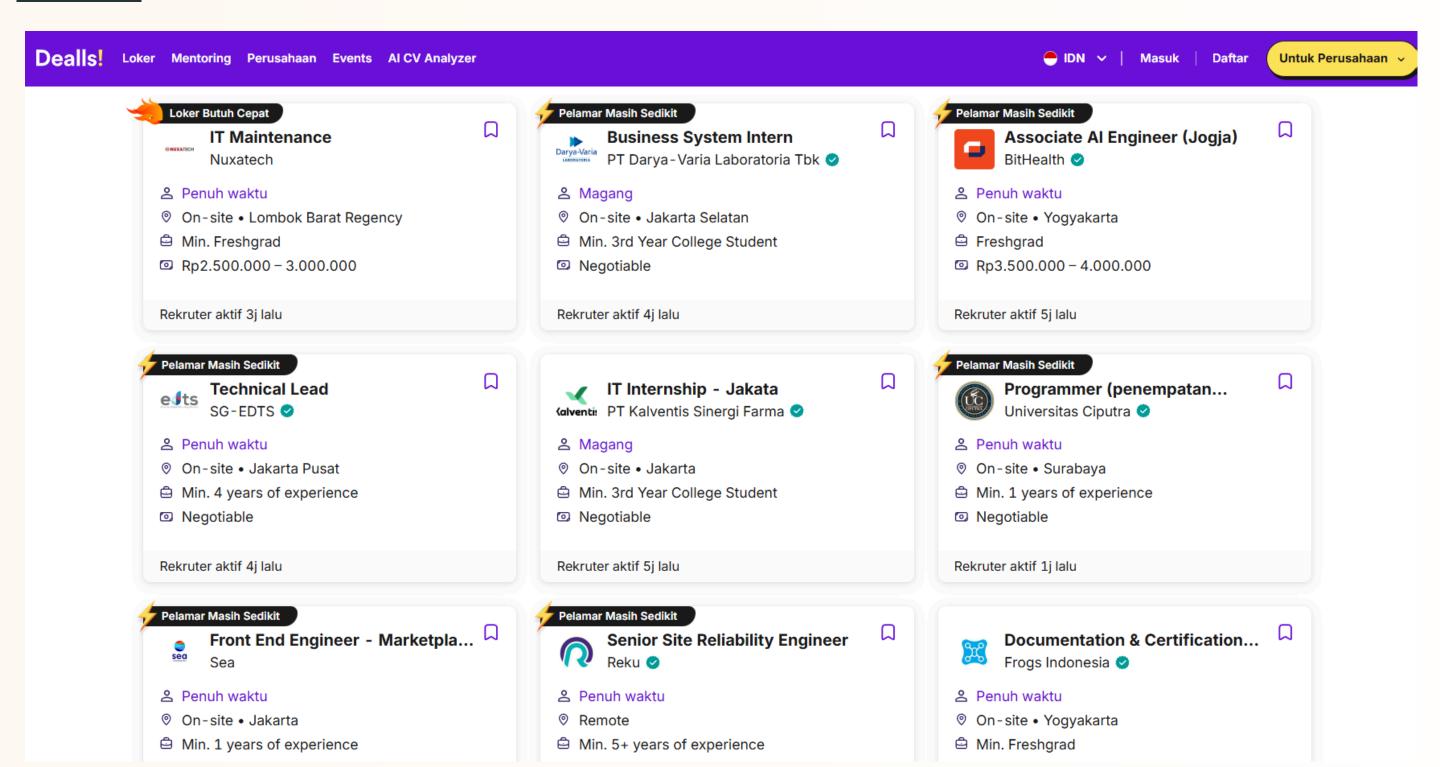
Kalibrr



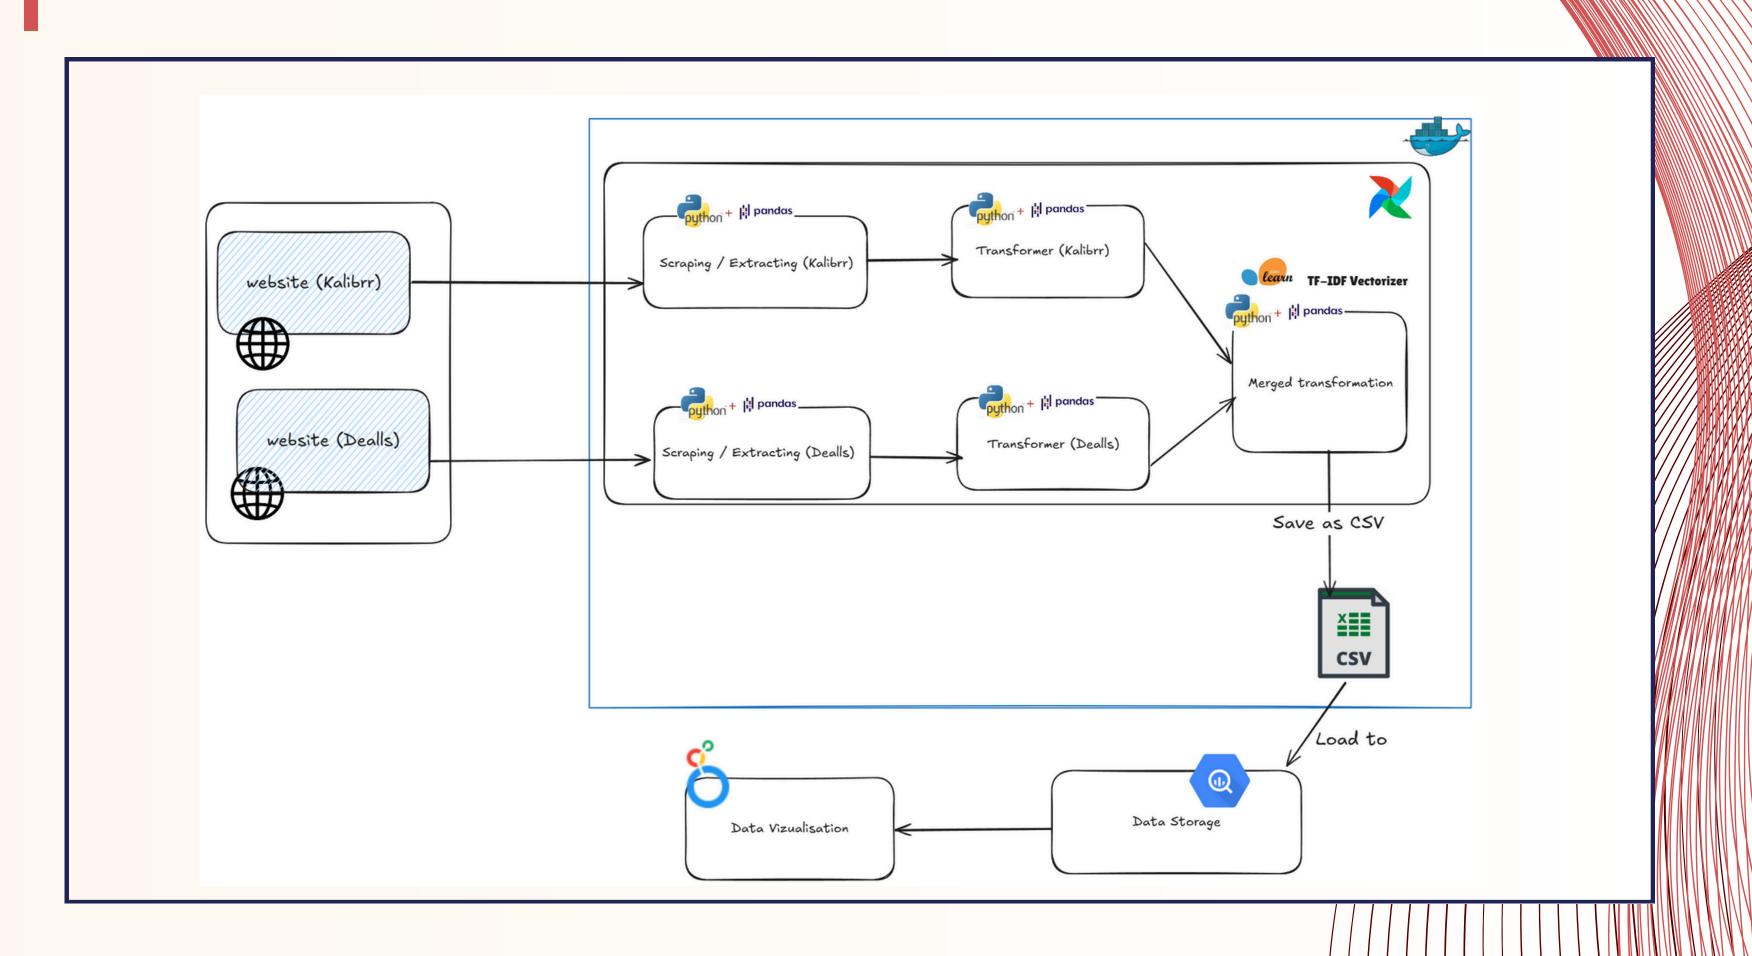
WHAT KIND OF DATA??

Data diperoleh dari metode web scraping menggunakan Request pada python. Website yang akan di-scraping tentunya adalah website-website yang legal untuk di-scraping

Dealls



DATA PLATFORM



TRANSFORMATION & CONSIDERATIONS

TRANSFORMATION & CONSIDERATION

1. Processing Method

- Multithreading to scrap different pages
- Batch Processing (daily)

2. Tools Use

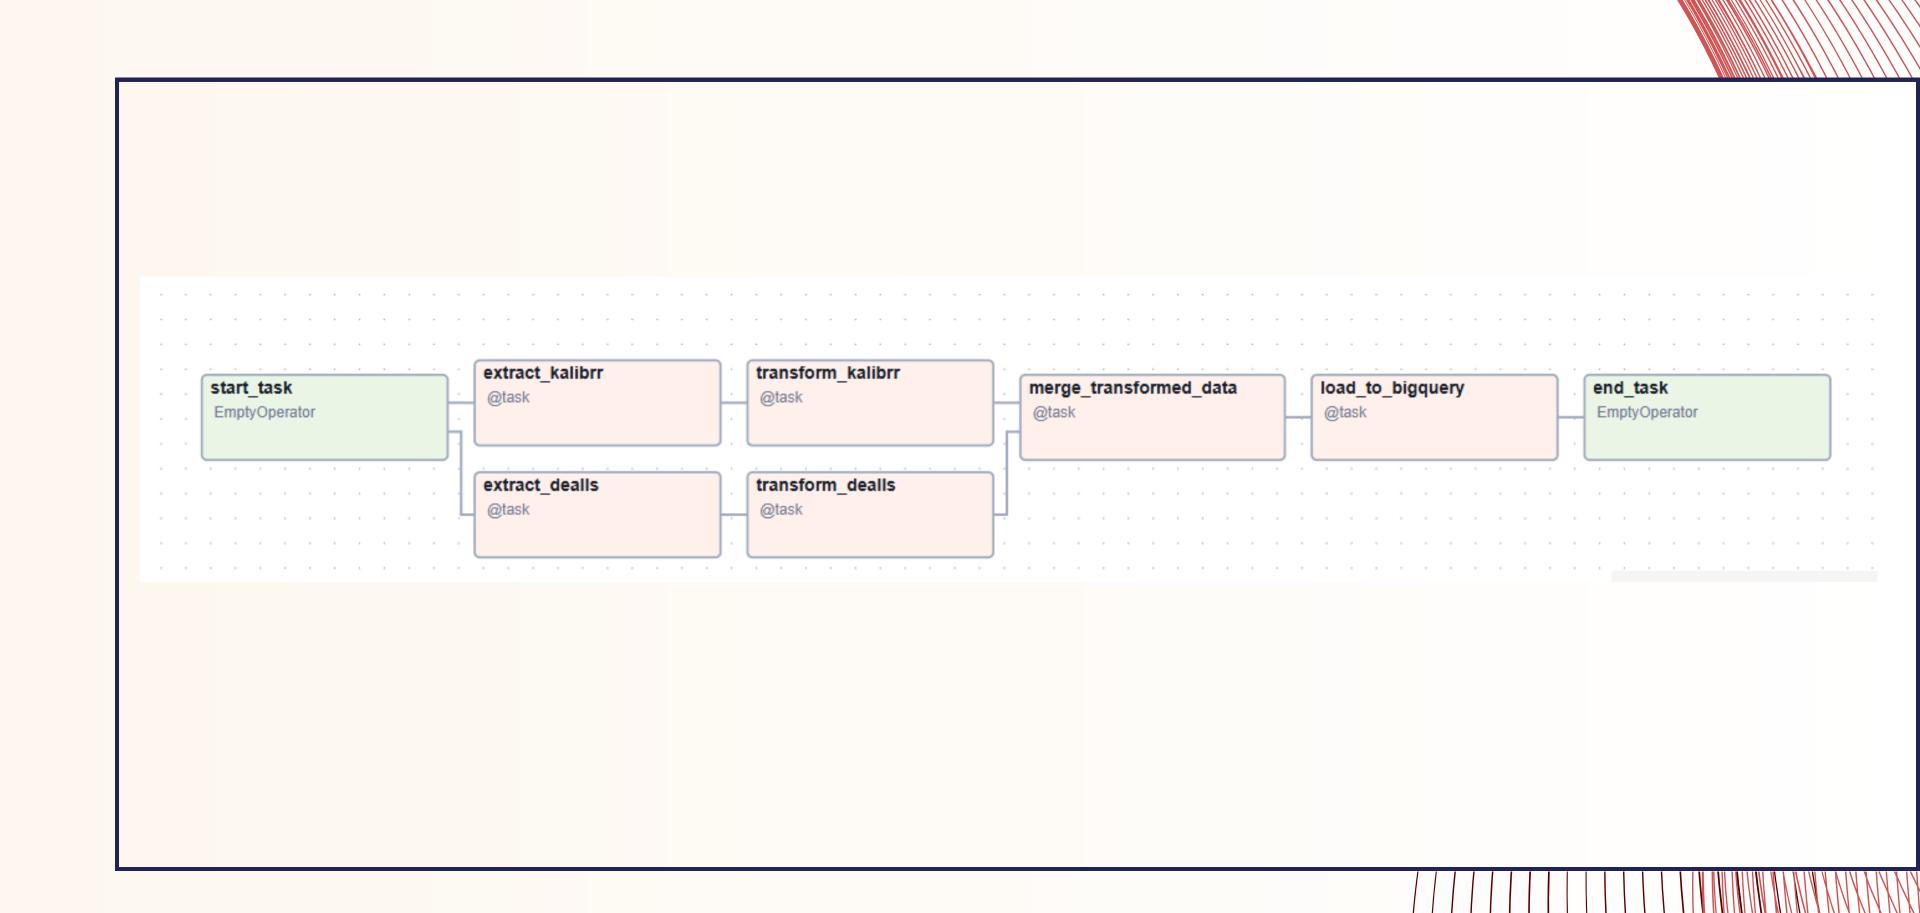
- Requests: To scrap the websites
- Pandas: To process and transform a medium-level-sized dataset

3. Key Transformation

- Handling Duplicate Values
- Standarization string colum job_title (using Tf-Idf vectorizer), and industry
- Replacing 'kabupaten', 'kota', 'regency' and grouping Area of Jakarta to be only

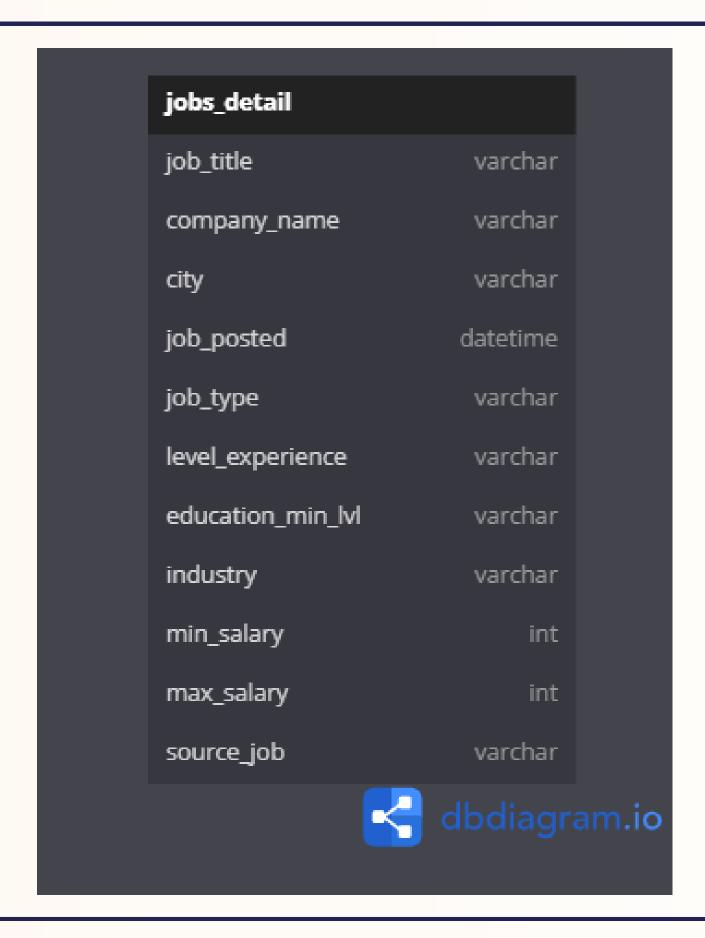
'Jakarta'

BATCH PROCESSING



DATA MODELING (BUSINESS)

DATA MODELING



CONCLUSION & RECOMENDATION (BUSINESS)

CONCLUSION

The data pipeline extracts data from two different web sources, **Kalibrr** and **Dealls**, using the Python library Requests. After the data is successfully extracted in each task, it undergoes a transformation process to filter out the words "kabupaten", "regency", and "kota", and to group all Jakarta areas into a single "Jakarta" category in the city column. Additionally, transformations are applied to the education_min_lvl and level_experience columns to convert their values into more meaningful ones.

Next, the data is merged and further transformed using scikit-learn (TF-IDF Vectorizer), particularly for the job_title and industry columns. The final transformation step involves removing duplicate values. The cleaned data is then stored in BigQuery and subsequently visualized using Looker Studio.

DATA VIZ

Looker Studio (link access)



RECOMMENDATION

- To perform web scraping where the data source can be directly retrieved from its API, the
 easiest way is to use the Requests library.
- Using multi-threading allows executing the scraping script for multiple pages simultaneously in a single iteration.
- With Looker Studio, the data source can be easily connected to Google BigQuery. If there are any changes in the data, we can simply click "Refresh dataset" on the Looker Studio dashboard.
- When transforming the job_title column, TF-IDF Vectorizer is needed to normalize strings if the job_title does not exist in the mapping_job_title.py file.

